Programmation, apply, et calcul parallèle

R Avancé

B.Thieurmel - benoit.thieurmel@datastorm.fr

Agrocampus Ouest

Un peu d'histoire...

R est un logiciel de Statistique distribué gratuitement par le **CRAN** créé dans les années 90 dans l'esprit de S :

- disponible sous de nombreux systèmes d'exploitation
- dédié à l'analyse statistique et à la visualisation
- environ 80% du temps de l'analyse est dédié à la préparation des données...
  - et donc aussi à la manipulation des données
- plus qu'un environnement statistique (SPSS, SAS, ...), un langage de programmation puissant, complet, et autonome
- composé d'un socle et de bibliothèques de fonctions thématiques regroupées sous le nom de **package**
- connectables avec (tous...) les autres langages : C, Fortran, Java, Python, Javacript, C++, ...
- et (toutes...) les bases de données : MySQL, Postgresql, Oracle, MS sql, mongodb, Hadoop, ...

- R est un langage **interprété**
  - == il requiert un autre programme, l'interprète, pour l'éxécution de ses commandes
  - != des langages **compilés**, comme le C ou le C++, qui sont d'abord convertis en code machine par le compilateur avant de pouvoir être éxécutés
- il est basé sur la notion de vecteur
  - simplifie les calculs
  - réduit l'utilisation des boucles
- pas de typage ni de déclaration obligatoire des variables
- avec une forte population grandissante d'utilisateurs et de développeurs
  - à la pointe un termes de méthodologies / technologies
- pour un temps de développement relativement court...

Bonne pratique de codage

Librement inspiré du Style Guide, by Hadley Wickham

- C'est important d'adopter des bonnes pratiques de codages :
  - permettre une lecture et une compréhension simple et rapide du code
  - tant pour le(s) développeur(s), que pour les utilisateurs, et favoriser le travail collaboratif
- Il n'y a pas un style parfait, le principal est d'en adopter un et de s'y tenir

```
# dur à lire
aze=data.frame(cole=rnorm(1000),refdzf=LETTERS[1:2]);ff=lapply(split(aze$cole,aze$refdzf),
                                                               function(x){mean(x)});ff
```

```r
# c'est mieux quand même... ?
data <- data.frame(value = rnorm(1000), group = LETTERS[1:2])
mean.group <- lapply(
  split(data$value, data$group),
  function(x){
    mean(x)
  })
mean.group
```

Fichiers

Les noms doivent être **explicites** et se terminer par `.R`. Si les scripts sont ordonnées, les pré-fixés par un numéro.

```
# Good            # Bad         0-download.R
modelisation.R    toto.r        1-parse.R
```

Variables et fonctions

- Noms **courts** et **explicites**, de préférence en minuscule, en évitant d'utiliser des noms de fonctions connues...
- Utilisation d'un underscore (`_`) pour séparer les noms. Eviter le point (`.`), il peut amener de mauvaises intéractions avec d'autres langages (java, javascript, ...)
- Variable == noms, fonctions == verbes, autant que possible....
- **Pas d'accents !**

```r
# Good                    # Bad
day_one                   first_day_of_the_month
day_1                     DayOne
                          mean <- function(x) sum(x)
```

Espacer son code

- Mettre des espaces **autour** de tous les opérateurs (`=`, `+`, `-`, `<-`, etc.), **surtout** à l'intérieur de l'appel d'une fonction.
- Mettre un espace **après** une virgule, **pas avant**
- Essayer de mettre un espace avant l'ouverture d'une parenthèse, **sauf dans l'appel d'une fonction**

```r
# Good
average <- mean(feet / 12 + inches, na.rm = TRUE)

# Bad
average<-mean(feet/12+inches,na.rm=TRUE)
```

- Exception pour `:`, `::` and `:::`

```r
# Good                    # Bad
x <- 1:10                 x <- 1 : 10
base::get                 base :: get
```

```r
if (debug) do(x)          if(debug)do(x)
plot(x, y)                plot (x, y)
```

Accolades et indentation

- L'ouverture d'une accolade doit **toujours** être suivi d'un passage à la ligne.
- La fermeture d'un accolade doit être suivi d'un passage à la ligne, sauf dans le cas d'un **else**
- Le code à l'interieur des acccolades doit être indenté

```r
# Good                          # Bad
if (y == 0) {                   if (y == 0) {
  log(x)                          log(x)
} else {                        }
  y ^ x                         else{ y ^ x}
}
```

- Indenter son code, de préférence en utilisant deux espaces. **Raccourci RStudio : Ctrl+A, Ctrl+I**
- Cas particulier dans la définition d'une fonction

```r
long_function_name <- function(a = "a long argument",
                               b = "another argument",
                               c = "another long argument") {
  # As usual code is indented by two spaces.
}
```

Assignement

- Utiliser `<-`, et **banir** `=`, lors de l'assignement

```r
# Good
x <- 5
# Bad
x = 5
```

Commentaires

- Commenter son code, toujours dans un soucis de lecture et de collaboration

```r
# Load data ---------------------------

# Plot data ---------------------------
```

Structures condionnelles

if / else/ else if

```r
if(condition1){
  print("la condition1 est vrai")
}else if(condition2){
  print("la condition1 est fausse, mais la condition2 est vrai")
}else{
  print("les conditions sont fausses... :-(")
}
```

- la condition doit retourner une (**et une seule**) valeur logique (TRUE/FALSE)

ifelse, une variante

```r
ifelse(vecteur.condition, vecteur.vrai, vecteur.faux)
```

- Pour chaque élément *i*, regarde *condition[i]*, et retourne *vrai[i]* ou *faux[i]*

```r
x <- 1:2
ifelse(x%%2 == 0, 0, x)      #> [1] 1 0
```

---

switch

- Suivant les cas, une autre façon de faire un **if / else if**

```r
res <-  switch(valeur,
         cas1 = resultat1,
         cas2 = resultat2,
         cas3 = resultat3,
         sinon (optionnel))
```

```r
fonction <- "mean"
x <- rnorm(100)
res <-  switch(fonction,
         mean = mean(x),
         median = mean(x),
         sum = sum(x))
res
```

```
## [1] -0.2926694
```

Opérateurs logiques

- ==, !=, >, <, >=, <=

```r
x <- 1

x == 1  # TRUE
x != 1  # FALSE
x < 1   # FALSE

vx <- c(1, 2)
vx != 1 # FALSE TRUE
```

- **any** : retourne vrai si au-moins un élément répond à la condition

```
x <- c(1:10)

any(x == 10) # TRUE
any(x > 10)  # FALSE
```

- **all** : retourne vrai si tous les éléments répondent à la condition

```
x <- c(1:10)

all(x <= 10) # TRUE
all(x > 10)  # FALSE
```

- **%in%** : vérifie l'appartenance de chaque élément d'un vecteur à un autre ensemble

```
x <- "rennes"
x %in% c("rennes", "brest") # TRUE

x <- c("rennes", "paris")
x %in% c("rennes", "brest") # TRUE FALSE
```

- **is.vector**, **is.data.frame**, **is.list**, ...

```
x <- c(1:10)

is.vector(x) # TRUE
```

- **!** : retourne la négation

```
x <- 1
y <- 10

(x == 1 & y == 10)   # TRUE
!(x == 1 & y == 10)  # FALSE
```

- **&** (**&&**) : opérateur logique 'AND'. Vrai si les deux conditions sont vraies, faux sinon

```
(x == 1 & y == 10)   # TRUE
(x == 1 & y == 9)  # FALSE
```

- **|** (**||**) : opérateur logique 'OR'. Vrai si au-moins une des deux conditions est vrai, faux sinon

```
(x == 1 || y == 10)   # TRUE
(x == 1 || y == 9)    # TRUE
(x == 2 || y == 9)    # FALSE
```

- **xor** : opérateur logique 'OR' exclusif. Vrai si une et une seule condition est vrai, faux sinon

```
xor(TRUE, FALSE) # TRUE
xor(TRUE, TRUE)  # FALSE
```

Les boucles

- Rarement efficaces...
- Donc à utliser avec précautions dans **R**
- Utiliser de préférence les propriétés offertes par la **vectorisation**, et la **"Apply Family"**

For

On parcourt un ensemble d'éléments

```
for(variable in elements){
  ...
}
```

```
for(lettre in LETTERS[1:2]){
  print(lettre)
}
```

```
## [1] "A"
## [1] "B"
```

While

- Tant que la condition est vrai, on continue
  - Si elle est fausse au départ, rien ne s'éxécute
  - Si elle est toujours vrai, ou si il n'y a pas de sortie **explicite**, elle continue à tourner...!

```
while(condition){
  ...
}
```

```
x <- 1
while(x < 4){
  print(x)
  x <- x+1
}
```

```
## [1] 1
## [1] 2
## [1] 3
```

Repeat

- Tant qu'on ne sort pas, on continue
  - L'éxécution a donc lieu au-moins une fois
  - Utilisation de **break** pour sortir

```
repeat{
  ...
  if(condition) break
}
```

```r
x <- 1
repeat{
  x <- x+1
  if(x == 3){
    print("x vaut 3, on s'arrête.")
    break
  }
}
```

```
## [1] "x vaut 3, on s'arrête."
```

Break et next

- **break** : Sortie immédiate d'une boucle **for**, **while** ou **repeat**
- **next** : Itération suivante d'une boucle **for**, **while** ou **repeat**

```r
for(i in 1:3){
  if(i%%2 != 0) {
    next
  }
  print(i)
}
```

```
## [1] 2
```

Un petit mot sur la vectorisation

'*La vectorisation est le processus de conversion d'un programme informatique à partir d'une implémentation scalaire, qui traite une seule paire d'opérandes à la fois, à une implémentation vectorielle qui traite une opération sur plusieurs paires d'opérandes à la fois. Le terme vient de la convention de mettre les opérandes dans des vecteurs ou des matrices.*' (Wikipédia)

- R est un langage **interprété**
- Beaucoup de calculs pouvant être réalisés par une boucle peuvent se faire en utilisant la vectorisation, avec une performance accrue :
  - opérations sur des vecteurs
  - opérations sur des matrices (= un ensemble de vecteurs)
  - opérations sur des data.frame
- Une performance accrue, pourquoi ?
  - **R**, et ses fonctions "de base" sont codés en **C**, **Fortran**, ...
  - avec l'utilisation efficace et optimisée dans "routines" d'algèbre linéaire (*BLAS*, *LAPACK*, ...)

Cas exemple : la somme de deux vecteurs

```r
x <- rnorm(100000)
y <- rnorm(100000)
res <- rep(0, 100000)
```

```r
# calcul de la somme via une boucle
system.time(for(i in 1:100000){
  res[i] <- x[i] + y[i]
})
```

```
##    user  system elapsed
##    0.16    0.00    0.16
```

```r
# avec la vectorisation
system.time(res2 <- x + y)
```

```
##    user  system elapsed
##       0       0       0
```

```r
identical(res, res2)
```

```
## [1] TRUE
```

Y penser donc pour notamment :

- opérations entre vecteurs / matrices

```r
x <- matrix(ncol = 2, nrow = 2, 1)
y <- matrix(ncol = 2, nrow = 2, 2)

z <- x + y
z
```

```
##      [,1] [,2]
## [1,]    3    3
## [2,]    3    3
```

- Création / modification de colonne

```r
data <- data.frame(x = 1:10, y = 100:109)
data$z <- data$x + data$y
head(data, n = 2)
```

```
##   x   y   z
## 1 1 100 101
## 2 2 101 103
```

Les fonctions

On définit une nouvelle fonction avec la syntaxe suivante :

`fun <- function(arguments) expression`

- **fun** le nom de la fonction
- **arguments** la liste des arguments, séparés par des virgules. *formals(fun)*
- **expression** le corps de la fonction. une seul expression, ou plusieurs entre des accolades. *body(fun)*

```r
test <- function(x) x^2
test              # function(x) x^2

formals(test)     # $x
```

```r
body(test)        # x^2
environment(test) # <environment: R_GlobalEnv>
```

- Une fonction appartient à un environnement. Le plus souvent un package, ou alors l'environnement global **GlobalEnv**. *environment(fun)*

Les arguments

- **Valeur par défaut**
  - via une affetaction, avec '=', dans la définition de la fonction
  - optionnel lors de l'appel

```r
test <- function(x, y = 2){
  x + y
}
test(x = 2)           # 4
test(x = 2, y = 10)   # 12
```

- **Quelques fonctions utiles de contrôle :**
  - *missing(arg)* : retourne TRUE si l'argument est manquant lors de l'appel
  - *match.arg()* : en cas d'input tronqué...
  - *typeof(arg)*, *class(arg)*, *is.vector()*, *is.data.frame()*, ...

```r
match.arg("mea", c("mean", "sum", "median"))  # "mean"
class(10)                                     # "numeric"
```

- **Dépendances entre arguments**

On peut définir un argument en fonction d'autres arguments

```r
# avec une expression simple
test <- function(x, y = x + 10){
  x + y
}
test(5)  # 20

# un peu plus compliqué
test <- function(x,
                 fun = if(class(x) %in% c("numeric", "integer")){
                   "sum"
                 }else{
                    "length"
                 }){

  do.call(fun, list(x = x))

}

test(1:10)            #55
test(LETTERS[1:10])   #10
```

- **Evaluation des arguments**

Point Important : les arguments ne sont évalués que lorsqu'ils sont appelés, sinon ils n'existent pas dans la fonction.... Pour forcer l'évaluation, on peut utiliser la fonction *force()*. Démonstration :

```
f <- function(x) {
  10
}
f(stop("This is an error!"))

# la fonction retourne 10 alors que l'argument est un stop...
# 10

# utilisation de force
f <- function(x) {
  force(x)
  10
}
f(stop("This is an error!"))

# Error: This is an error!
```

Comprendre les '...'

- Signifie que la fonction accepte d'autres arguments que ceux définis explicitement
- Sert généralement à passer ces arguments à une autre fonction
- Se récupère facilement avec : *list(...)*

```
viewdot <- function(arg, ...){
  list(...)
}
viewdot(arg = 1, x = 2, name = "name")

#$x
#[1] 2
#
#$name
#[1] "name"

rnormPlot <- function(n, mean = 0, sd = 1, ...){
  plot(rnorm(n = n, mean = mean, sd = sd), ...)
}
rnormPlot(n = 100, main = "Comprendre les ...", col = "red", pch = 10)
```

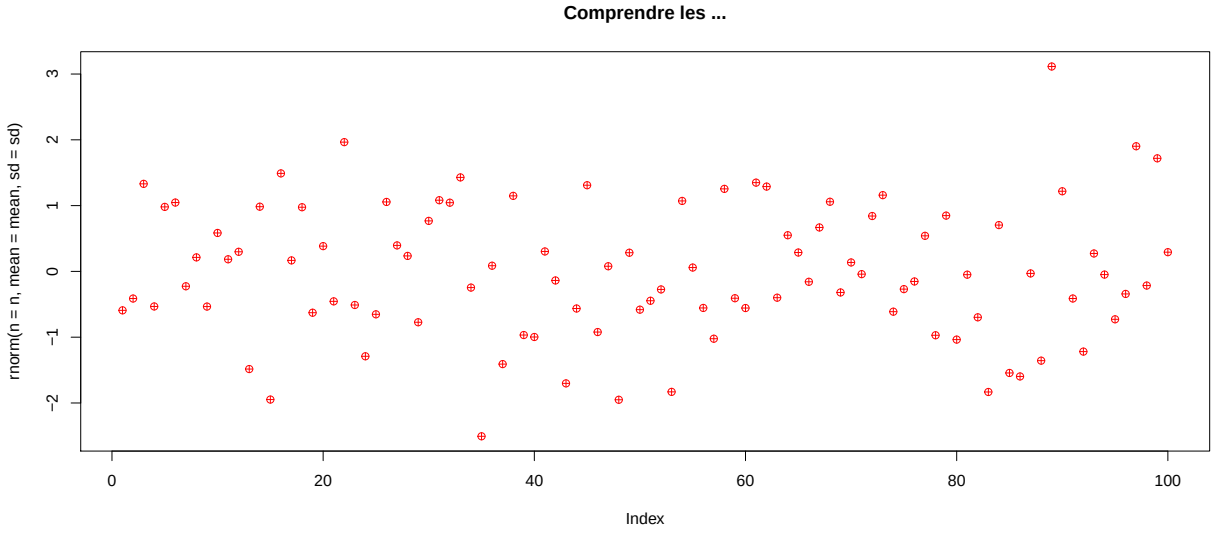

Retourner un résultat

Une fonction retourne par défaut le résultat de la dernière expression

```
test <- function(x, y = 2){
  x + y
}
test(2)
```

```
## [1] 4
```

```
somme <- test(x = 2, y = 2)
somme
```

```
## [1] 4
```

- Renvoi d'un résultat avant la fin de la fonction : fonction *return()*
- Utilisation de *return()* pour la dernière expression ? **Inutile**.
- Retour de plusieurs résultats : liste nommée.
- Aucun résultat ? Possible avec par example la fonction *invisible()*

- Utilisation de la fonction *return()*

```
test <- function(x, y = 2){
  if(y == 0){
    return(x)
  }
  x + y
}
test(2)
```

```
## [1] 4
```

- Plusieurs résultats

```r
test <- function(x, y = 2){
  list(x = x, y = y)
}
test(2)
```

```
## $x
## [1] 2
##
## $y
## [1] 2
```

- La fonction *invisible*()

"This function can be useful when it is desired to have functions return values which can be assigned, but which do not print when they are not assigned"

```r
test <- function(x, y = 2){
  x + y
  invisible()
}
test(2)  # no print on console
res <- test(2)
res     # and NULL result
```

```
## NULL
```

```r
test <- function(x, y = 2){
  invisible(x + y)
}
test(2)  # no print on console
res <- test(2)
res      # but a result !
```

```
## [1] 4
```

Variables locales et globales

- Une variable définie dans une fonction est **locale** :
  - elle ne sera pas présente ensuite dans l'espace de travail
  - elle n'écrasera pas une variable du même nom existante

```r
x <- 100
test <- function(x, y){
  x <- x + y
  x
}

# la fonction retourne bien 10
test(5, 5)
```

```
## [1] 10
```

```r
# et x vaut bien toujours 100
x
```

```
## [1] 100
```

- Via l'opérateur d'affectation `<<-`, on peut affecter au modifier une variable **globale**
- Autant que possible non-recommandé...!

```
x <- 100
test <- function(x, y){
  x <<- x + y
  y <<- y
  x
}

# la fonction retourne ...  5 ?
test(5, 5)
```

```
## [1] 5
```

```
# et x vaut maintenant 10, et y 5
x ; y
```

```
## [1] 10
```

```
## [1] 5
```

- **Et si la fonction utilise une variable non-définie ?**

```
test <- function(x){
  x + z
}

# Erreur, z n'existe pas
test(5)

#> Error in test(5) : object 'z' not found

# Si, à tout hasard, une variable 'z' existe dans un autre environnement
# au moment de l'appel, la fonction l'utilise...
z <- 5
test(5)

#> 10
```

- **R** va chercher une variable d'une même nom dans les environnements *parents*.
- Pratique également à éviter. Il faut mieux passer **tous** les arguments en paramètres

---

Fonctions anonymes

Comme son nom l'indique, une fonction qui n'a pas de nom...

- fonction courte, utilisée dans une autre fonction
- qui n'a pas pour but d'être ré-utilisée par la suite

```
f <- function(x){
  x + 1
```

```
}

res1 <- sapply(1:10, f)

res2 <- sapply(1:10, function(x) x + 1)

res1
```

```
##  [1]  2  3  4  5  6  7  8  9 10 11
```

```
res2
```

```
##  [1]  2  3  4  5  6  7  8  9 10 11
```

Communication

Quand on développe, il est important d'anticiper les problèmes potentiels du code :

- mauvais type d'argument
- fichier non-existant
- données manquantes, valeurs infinies, ...

Et communiquer avec l'utilisateur. Trois niveaux sont disponibles :

- fonction *stop()* : erreur "fatale", l'éxécution se termine. A utiliser quand la suite du code ne peut pas être éxécutée
- fonction *warning()* : problème "potentielle", l'éxécution continue, mais il y aura peut-être un soucis...
- fonction *message()* : message "informatif", l'éxécution continue.

```
test <- function(x){
  # pour une erreur plus compréhensible
  if(missing(x)){
    stop("x is missing. Please enter a valid argument")
  }
  if(!class(x) %in% c("numeric", "integer")){
    x <- as.numeric(as.character(x))
    warning("x is coerced to numeric")
  }
  message("compute x*2")
  x*2
}

try(test())

#> Error: x is missing. Please enter a valid argument

test("5")
```

```
## Warning in test("5"): x is coerced to numeric
```

```
## compute x*2
```

```
## [1] 10
```

Gestion des erreurs et des messages

Quand **R** rencontre une erreur, il s'arrête net. Dans certains cas, on voudrait pouvoir continuer notre calcul. Trois fonctions sont diponibles dans R :

- *try()* : la plus simple, pour continuer l'éxécution malgré une erreur
- *tryCatch()* : permet de décider de ce qui se passe quand le code rencontre une erreur, un warning, ou un message
- *withCallingHandlers()* : une variante de tryCatch()

```
test <- sapply(list(1:5,"a", 6:10), log)
#>Error in FUN(X[[2L]], ...) :
#  non-numeric argument to mathematical function
```

```
test <- sapply(list(1:5,"a", 6:10), function(x) try(log(x), silent = TRUE))
test
```

```
## [[1]]
## [1] 0.0000000 0.6931472 1.0986123 1.3862944 1.6094379
##
## [[2]]
## [1] "Error in log(x) : argument non numérique pour une fonction mathématique\n"
## attr(,"class")
## [1] "try-error"
## attr(,"condition")
## <simpleError in log(x): argument non numérique pour une fonction mathématique>
##
## [[3]]
## [1] 1.791759 1.945910 2.079442 2.197225 2.302585
```

```
# on récupére un object de class "try-error", avec le message d'erreur
class(test[[2]])
```

```
## [1] "try-error"
```

```
test[[2]][1]
```

```
## [1] "Error in log(x) : argument non numérique pour une fonction mathématique\n"
```

Et la documentation dans tout ça ?

La documentation est très importante :

- pour que l'utilisateur sache comment utiliser la fonction
- pour vous et d'autres développeurs, lors d'améliorations

Adopter la convention *doxygen*

- simple d'utilisation
- utiliser dans de nombreux langages de programmation
- via le package roxygen2, vous simplifiera ensuite la vie si vous créer des packages !

Utilisation dans R

- en commençant la ligne par `#'`

Les balises indispensables

- @param : pour les arguments
- @return : pour le résultat
- @examples : pour les exemples

```
#' le titre de ma fonction
#'
#' Une description succinte de ma fonction
#' sur plusieurs lignes si on veut
#'
#' @param nom : Character. Nom de la personne
#' @param prenom : Character. Prénom de la personne
#'
#' @return : Character. Identification de la personne
#'
#' @examples
#' # les examples sont éxécutables dans RStudio avec Ctrl+Entrée
#' identifier("Thieurmel", "Benoit")
identifier <- function(nom, prenom){
  paste0("Nom :", nom, ", prénom : ", prenom)
}
```

Un petit mot sur le déboggage

- Pour voir les informations : utilisation de *print()* dans la fonction
- Quand une erreur se produit, utilisation du **traceback**
  - Disponible par défaut dans la console RStudio
  - via la fonction *traceback()* dans R

La "Apply family"

R donc pas au top pour interpréter et éxécuter efficacement des boucles **for**

"Et donc ?"

- Une solution **radicale** : NE PAS LES UTILISER !

"Et alors, comment je fais ?"

- Penser à la vectorisation
- Utiliser la **"Apply family"**
  - **apply** : appliquer une fonction sur un data.frame, une matrice, ou un tableau multi-dimentionnel
  - **lapply** : appliquer une fonction sur une liste, ou un vecteur, et retourne une liste
  - **sapply** : identique à **lapply**, mais essaye de structurer un peu mieux les résultats si cela est possible
  - **vapply** : identique à **sapply**, en permettant de définir (un peu) le format des résultats

– **mapply** : prend en entrée plusieurs vecteurs/listes, et applique la fonction sur les premiers éléments de chaque entrées, puis sur les seconds, ...
– **rapply** : éxécution récursive de **apply**, avec contrôle préalable des éléments

---

Apply

```
apply(X, MARGIN, FUN, ...)
```

- **X** : une matrice ou un tableau
- **MARGIN** : un vecteur d'entiers contenant la ou les dimensions sur lesquelles on souhaite appliquer la fonction (1 : lignes, 2 : colonnes)
- **FUN** : la fonction à appliquer
- **...** : ensemble d'arguments supplémentaires, à passer à la fonction

```
x <- cbind(x1 = 3, x2 = c(NA, 4:1, 2:6))
apply(x, 2, mean)                    # moyenne par colonnes
```

```
## x1 x2
##  3 NA
```

```
apply(x, 2, mean, na.rm = TRUE)     # en passant un argument
```

```
##       x1       x2
## 3.000000 3.333333
```

---

lapply, sapply, vapply

```
lapply(X, FUN, ...)

sapply(X, FUN, ..., simplify = TRUE, USE.NAMES = TRUE)

vapply(X, FUN, FUN.VALUE, ..., USE.NAMES = TRUE)
```

- **X** : un vecteur ou une liste
- **FUN** : la fonction à appliquer à tous les éléments de X
- **...** : ensemble d'arguments supplémentaires, à passer à la fonction
- **simplify** : booléan ou caractère, pour simplifier les résultats
- **USE.NAMES** : booléan. Si X est nommé, les utiliser dans les résultats ?
- **FUN.VALUE** : un "template" pour les résultats

Essayons de comprendre ces petites différences...

---

1. Calcul de la moyenne, soit une valeur par élément

- les données de départ :

```
x <- list(a = 1:3, b = rnorm(5))
```

```
## $a
## [1] 1 2 3
##
```

```
## $b
## [1]  1.1957295 -0.9920022 -1.6377174  0.1726118  0.1050878
```

- lapply retourne donc une liste

```
lapply(x, FUN = mean)
```

```
## $a
## [1] 2
##
## $b
## [1] -0.2312581
```

- sapply simplifie les résultats dans un vecteur

```
sapply(x, FUN = mean)
```

```
##          a          b
##  2.0000000 -0.2312581
```

- vapply attend une précision sur le résulat

```
# on s'attend à récupérer une valeur numérique
vapply(x, FUN = mean, FUN.VALUE = 0)
```

```
##          a          b
##  2.0000000 -0.2312581
```

```
# et si on s'attend à récupérer une valeur logique ?
vapply(x, FUN = mean, FUN.VALUE = TRUE)

# Error in vapply(x, FUN = mean, FUN.VALUE = TRUE) :
#   values must be type 'logical',
#  but FUN(X[[1]]) result is type 'double'
```

---

2. Calcul des quantiles, soit 5 valeurs par éléments

- lapply retourne donc une liste

```
lapply(x, FUN = quantile)
```

```
## $a
##   0%  25%  50%  75% 100%
##  1.0  1.5  2.0  2.5  3.0
##
## $b
##         0%        25%        50%        75%       100%
## -1.6377174 -0.9920022  0.1050878  0.1726118  1.1957295
```

- sapply simplifie les résultats dans une matrix

```
sapply(x, FUN = quantile)
```

```
##        a          b
## 0%   1.0 -1.6377174
## 25%  1.5 -0.9920022
## 50%  2.0  0.1050878
## 75%  2.5  0.1726118
```

```
## 100% 3.0  1.1957295
```

- Formattage avec vapply

```
vapply(x, FUN = quantile, FUN.VALUE = c(Min. = 0, "1st Qu." = 0,
  Median = 0, "3rd Qu." = 0, Max. = 0))
```

```
##           a          b
## Min.    1.0 -1.6377174
## 1st Qu. 1.5 -0.9920022
## Median  2.0  0.1050878
## 3rd Qu. 2.5  0.1726118
## Max.    3.0  1.1957295
```

3. Et si on retourne un nombre variable d'éléments ?

```
la <- lapply(x, FUN = function(elm) elm)
sa <- sapply(x, FUN = function(elm) elm)
# vapply pas pertinent

identical(la, sa)
```

```
## [1] TRUE
```

---

mapply

```
mapply(FUN, ..., MoreArgs = NULL, SIMPLIFY = TRUE,
       USE.NAMES = TRUE)
```

- **FUN** : la fonction à appliquer
- **...** : ensemble d'arguments, vecteurs ou listes
- **MoreArgs** : liste d'arguments supplémentaires pour la fonction
- **SIMPLIFY** : booléan ou charactère, pour simplifier les résultats
- **USE.NAMES** : booléan. Si noms il y a dans X, les utiliser dans les résultats ?

```
mapply(rep, 1:2, 2:1)
```

```
## [[1]]
## [1] 1 1
##
## [[2]]
## [1] 2
```

```
# en nommant les arguments
mapply(rep, times = 1:2, x = 2:1)
```

```
## [[1]]
## [1] 2
##
## [[2]]
## [1] 1 1
```

```r
# en passant des arguments supplémentaires
mapply(rep, times = 1:2, MoreArgs = list(x = 100))
```

```
## [[1]]
## [1] 100
##
## [[2]]
## [1] 100 100
```

```r
# Avec simplification des résultats
mapply(function(n, moy) mean(rnorm(n, moy)), n = c(100, 1000), moy = c(10, 0))
```

```
## [1] 9.920368412 0.006180223
```

Le calcul parallèle

Concept

- Calcul séquentiel
  - un problème est divisé en une série d'instructions
  - les instructions sont éxécutées les une après les autres
  - sur un unique processeur
  - Seulement une instruction s'éxécute à la fois

- Calcul parallèle
  - un problème est divisé en plusieurs séries d'instructions qui peuvent être éxécutées en même temps
  - les instructions de chaque série s'éxécute simultanément sur différents processeurs
  - cela nécessite un méchanisme de contrôle et de synchronisation

'l'ensemble des techniques logicielles et matérielles permettant l'exécution simultanée de séquences d'instructions indépendantes sur des processeurs et/ou coeurs différents'

Le problème algorithmique est donc :

- pouvoir diviser tout ou une partie en sous-calculs indépendants
- pouvoir éxécuter plusieurs instructions à un moment donné
- résoudre le problème en moins de temps qu'avec un calcul séquentiel

Les ressources matérielles à disposition :

- un unique ordinateur, avec plusieurs processeurs / coeurs
- un cluster d'ordinateurs inter-connectés

Quand paralléliser ?

- quand chaque calcul commence à prendre un peu de temps...
- calculer plusieurs tâches rapides en parallèle prend en général plus de temps qu'avec un calcul séquentiel...
- faire attention au partage des données, et regarder l'évolution de la performance en fonction du nombre de coeurs

- le mieux : tester et comparer !

---

les outils dans R

- A la base, **R** est mono-coeur
- De nombreux packages permettant le calcul parallèle existent

Nous nous focaliserons sur deux packages :

- le package **parallel**
  - inclu dans R depuis R.2.14.0
  - basé sur deux "anciens" packages : **snow** et **multicore**
  - propose une interface très proche de la **'Apply family'**
- le package **foreach**

```
require(parallel)
vignette("parallel")

require(foreach)
vignette("foreach")
```

---

le package parallel

Le processus général :

- ouverture d'un "cluster"
  - **makeCluster()**
  - ouverture de sessions **R** temporaires
  - fonction utile : **detectCores()**, nombre de CPU coeurs sur la machine
- utilisation du "cluster"
  - **clusterCall**, **clusterApply**, **clusterExport**, **clusterEvalQ**, ...
  - **parLapply**, **parSapply**, **parApply**, ...
- fermeture du "cluster"
  - sinon les sessions **R** temporaires restent ouvertes...
  - **stopCluster()**

---

exemple d'introduction

```
require(parallel)
nb.cores <- detectCores() # 8
nb.cores
```

```
## [1] 4
```

```
# mieux vaut éviter d'utiliser toutes les ressources
cl <- makeCluster(nb.cores - 1)
res <- clusterApply(cl, 1:7, function(x){ rnorm(x)})
str(res)
```

```
## List of 7
##  $ : num 0.662
##  $ : num [1:2] 0.787 -0.714
##  $ : num [1:3] 0.251 -0.738 -1.664
##  $ : num [1:4] -1.552 1.882 -0.257 -0.593
##  $ : num [1:5] -0.394 -0.074 0.966 -0.587 0.345
##  $ : num [1:6] -2.0061 0.1826 0.1955 -0.0503 1.8538 ...
##  $ : num [1:7] -0.0305 1.8991 -0.9958 0.519 0.5299 ...
```

```r
stopCluster(cl)
```

Points importants

chargements des données / packages

- les sessions **R** temporaires sont "vides" (sauf en Linux/Mac, avec l'option *makeCluster(, type="FORK")*)
  - aucunes variables / aucuns packages de la session principale sont présents
- **clusterExport** : exporte les variables / fonctions souhaitées
- **clusterEvalQ** : éxécute un code dans toutes les sessions. Utile pour charger un package notamment

load-balancing

- Généralement, les p premiers calculs sont envoyés aux p sessions ouvertes
- les calculs suivants débutent lorque **tous** les p calculs ont été effectués
- Dans le cas de calculs de temps différents, on perd de la performance
- des versions LB, **load-balancing**, existent pour enchaîner sur un nouveau calcul dès que le précédent se termine

---

Chargement des données : illustration

```r
cl<-makeCluster(2)
add <- 10
mult <- function(x) x * 2

parLapply(cl, 1:10, function(x)  mult(x) + add)

# les noeuds ne connaissent pas la variable et la fonction
# Error in checkForRemoteErrors(val) :
#  2 nodes produced errors; first error: objet 'mult' introuvable

# on les exporte avant de lancer le calcul

clusterExport(cl, varlist = c("add", "mult"))

res <- parLapply(cl, 1:10, function(x)  mult(x) + add)

res[[1]] # 12
```

```r
stopCluster(cl)
```

Chargement d'un package : illustration

```r
cl<-makeCluster(2)
data(iris)

parLapply(cl, split(iris[, -c(5)], iris$Species), function(subdata){
  rpart(Sepal.Length~., subdata)
})

# les noeuds ne connaissent pas la variable et la fonction
# Error in checkForRemoteErrors(val) :
#  2 nodes produced errors; first error: impossible de trouver la fonction "rpart"

# on charge le package
clusterEvalQ(cl, {
  require(rpart)
})

res <- parLapply(cl, split(iris[, -c(5)], iris$Species), function(subdata){
  rpart(Sepal.Length~., subdata)
})

stopCluster(cl)
```

---

le package et la fonction foreach

- ressemble à une boucle **for**
- mais avec l'utilisation de l'opérateur **%do%** ou **%dopar%** pour du parallèle
- et **retourne un résultat**, une liste par défaut

```r
require(foreach)

x <- foreach(i = 1:3) %do% sqrt(i)
# equivalent à lapply(1:3, sqrt)
x
```

```
## [[1]]
## [1] 1
##
## [[2]]
## [1] 1.414214
##
## [[3]]
## [1] 1.732051
```

---

structure du résultat : .combine

```
# un vecteur
x <- foreach(i = 1:3, .combine = "c") %do% sqrt(i)
x
```

```
## [1] 1.000000 1.414214 1.732051
```

```
# une matrice
x <- foreach(i=1:4, .combine = 'cbind') %do% rnorm(2)
x
```

```
##        result.1  result.2  result.3  result.4
## [1,] -1.4375125  1.583195 -0.560750 1.7129049
## [2,]  0.5364862 -0.611710 -1.936877 0.2502712
```

```
# une somme
x <- foreach(i = 1:3, .combine = "+") %do% i
x
```

```
## [1] 6
```

---

ajouter un filtre avant l'éxécution

- Similaire à **if**, mais avec l'utilisation de **when**

```
## Warning: package 'numbers' was built under R version 3.3.3
```

```
require(numbers)
foreach(n = 1:50, .combine = c) %:% when (isPrime(n)) %do% n
```

```
##  [1]  2  3  5  7 11 13 17 19 23 29 31 37 41 43 47
```

gérer les erreurs : .errorhandling

- par défaut, si une erreur se produit, l'éxécution s'arrête
- on peut continuer le calcul et récupérer les erreurs potentielles en mettant l'option **.errorhandling** à *pass*

```
foreach(n = 1:2, .errorhandling = "pass") %do% ifelse(n == 2, stop("erreur"), n)
```

```
## [[1]]
## [1] 1
##
## [[2]]
## <simpleError in ifelse(n == 2, stop("erreur"), n): erreur>
```

Calcul parallèle

- même principe qu'avec **parallel**, sauf qu'il faut explicitement enregister le cluster
- avec **doParallel**, ou **doMC**, **doMPI**,**doRedis**, **doRNG**, **doSNOW**

```r
require(foreach)
require(doParallel)

cl <- makeCluster(6)
# avec foreach, il faut enregistrer le cluster
registerDoParallel(cl)

res <- foreach(n = 1:6) %dopar% rnorm(x)
str(res)
```

```
## List of 6
##  $ : num [1:6] 1.526 1.744 -0.572 0.762 -0.445 ...
##  $ : num [1:6] -2.3445 -2.2083 0.5347 0.6162 0.0361 ...
##  $ : num [1:6] -0.324 -0.501 0.462 -1.318 -0.192 ...
##  $ : num [1:6] 0.8259 0.8378 0.607 -1.3385 0.0544 ...
##  $ : num [1:6] -0.496 -0.869 0.613 -0.509 0.13 ...
##  $ : num [1:6] -1.317 -0.753 1.858 -0.226 -0.319 ...
```

```r
stopCluster(cl)
```

Points importants

chargements des données / packages

- contrairement à l'utilisation du package **parallel**, toutes les variables de l'environnement courant sont exportées par défaut
- **.noexport** : ne pas exporter certaines variables
- **.export** : exporter des variables qui ne sont pas dans l'environnement courant
- **.packages** : chargement de package(s)

autres options utiles

- **.inorder** : résultats dans l'ordre d'entrée ? Défaut à **TRUE**. **FALSE** peux amener de meilleures performances
- **.verbose** : utile pour débogguer

Exemples

```r
cl<-makeCluster(2)
registerDoParallel(cl)

############################
#  chargement des données
############################

add <- 10
mult <- function(x) x * 2
```

```r
# pas besoin de charger les données avant
res <- foreach(n = 1:10) %dopar% (mult(n) + add)
res[[1]] # 12

############################
#  chargement d'un package
############################

res <- foreach(data = split(iris[, -c(5)], iris$Species), .packages = "rpart") %dopar%
  rpart(Sepal.Length~., data)

stopCluster(cl)
```

Retour sur la notion d'environnement

```r
y <- 10
f <- function(x, .export = NULL){
  cl<-makeCluster(2)
  registerDoParallel(cl)
  res <- foreach(i = x, .export = .export) %dopar% (i + y)
  stopCluster(cl)
  res
}

res <- f(2:10)
#  Error in (x + y) : task 1 failed - "objet 'y' introuvable"

res <- f(2:10, .export = "y")
res[[1]] # 12
```

- The R Manuals : https://cran.r-project.org/manuals.html
- R Contributed Documentation : https://cran.r-project.org/other-docs.html
- Advanced R by Hadley Wickham : http://adv-r.had.co.nz/
- R packages by Hadley Wickham : http://r-pkgs.had.co.nz/
- How-to go parallel in R - basics + tips : http://gforge.se/2015/02/how-to-go-parallel-in-r-basics-tips/
- State of the Art in Parallel Computing withR : http://www.jstatsoft.org/v31/i01/paper
- R tutorial on the Apply family of functions : http://www.r-bloggers.com/r-tutorial-on-the-apply-family-of-functions/
- A Tutorial on Loops in R - Usage and Alternatives : http://blog.datacamp.com/tutorial-on-loops-in-r/